

# 多角度改进高频量价选股模型

华泰研究

2025年3月21日 | 中国内地

深度研究

研究员 林晓明  
SAC No. S0570516010001 linxiaoming@htsc.com  
SFC No. BPY421 +(86) 755 8208 0134

研究员 何康, PhD  
SAC No. S0570520080004 hekang@htsc.com  
SFC No. BRB318 +(86) 21 2897 2202

联系人 卢炯, CFA  
SAC No. S0570123070272 lujiang@htsc.com  
+(86) 755 8249 2388

## 人工智能 89: 从因子端、模型端、标签端改进高频量价选股模型

随着市场微观结构研究的深入,高频量价数据在量化投资中的重要性日益凸显。传统的人工挖掘因子和简单模型方法难以充分捕捉高频数据中的复杂规律。本文从因子端、模型端、标签端三个角度,探讨对前期高频量价模型的改进:在因子端引入大语言模型生成的分钟线、等量 K 线和 tick 因子,以更全面地捕捉市场信息;在模型端采用 Transformer 架构,并借鉴 iTransformer 和 Crossformer 模型,通过引入变量间注意力机制,提升对高频数据的表征能力;在标签端将预测目标从未来 10 日总收益调整为未来 10 日逐日收益序列,以提供更细粒度的投资信号。

### 改进方向一: 引入大语言模型生成因子

我们利用大语言模型,分别基于分钟线、等量 K 线和 tick 数据各生成 100 个因子。其中,分钟线因子刻画了股票日内收益、价格波动、成交分布、量价相关性等特征;等量 K 线因子反映了股票在均匀成交量下的价格趋势、价格波动、收益分布等特征;tick 因子则捕捉了股票流动性、订单不平衡等特征。实证结果表明,相比于人工特征集,基于 GPT 特征集训练的深度学习因子在多个指标上表现更优,2017 年初至 2025 年 2 月底的周度 RankIC 达 11.18%,全 A 多头年化超额收益为 25.51%,在 80%成份股和无成份股约束场景下构建中证 1000 指数增强组合,年化超额收益分别达到 19.08% 和 20.67%,信息比率分别为 3.26 和 2.81。

### 改进方向二: 引入变量间注意力


Transformer 通过多头注意力捕捉输入序列中不同位置间的依赖关系; iTransformer 创新性地将时间序列维度反转,通过自注意力机制捕捉变量间的相关性; Crossformer 则通过两阶段注意力机制,同时捕捉多变量时间序列中跨时间和跨维度的复杂关系。回测结果显示, iTransformer 和 Crossformer 训练得到的因子在 RankICIR 和多头信息比率上均优于传统 Transformer 模型。三类模型集成后的复合因子表现更为突出,周度 RankIC 提升至 11.64%,全 A 多头年化超额收益达 25.94%,中证 1000 指数增强组合在 80%成份股和无成份股约束场景下的年化超额收益分别达到 20.25% 和 21.31%,信息比率分别为 3.60 和 3.18。

### 改进方向三: 引入收益序列预测

与直接预测总收益相比,逐日收益序列预测能够更好地捕捉市场短期波动特征,提供更细粒度的投资信号,同时充分利用了更高信息密度的标签数据。在收益序列预测场景中,Transformer 的 decoder 模块通过掩码多头注意力机制,在避免未来信息泄露的前提下学习目标序列间的依赖性,并通过多头注意力学习输入序列和目标序列之间的关联。测试结果表明,decoder 能够相对有效预测未来 10 日的逐日收益,但简单求和的方式可能会造成信息损失,其单因子测试和指数增强效果均不及传统的总收益预测模型。未来可探索多周期优化等更合适的应用场景,以充分发挥收益序列预测的优势。

风险提示:大模型生成的因子在回测中存在引入未来信息的风险。高频量价模型对市场微观结构的依赖较强,未来市场变化可能导致模型失效。Transformer 架构的复杂性会带来训练和推理时间增加,以及过拟合风险。

## 改进因子的分层相对净值



资料来源: Wind, 华泰研究

正文目录

研究导读 .....	4
因子端：引入大语言模型生成因子 .....	6
因子构建.....	6
因子训练.....	6
因子测试.....	7
指增测试.....	8
因子相关性分析.....	10
模型端：引入变量间注意力 .....	11
模型介绍.....	11
因子测试.....	12
指增测试.....	13
因子相关性分析.....	15
标签端：引入收益序列预测 .....	16
因子测试.....	17
指增测试.....	18
因子相关性分析.....	19
总结 .....	20
风险提示.....	20
参考文献.....	20

图表目录

图表 1： 基于 GRU 的高频因子模型.....	4
图表 2： 多角度改进高频因子模型 .....	4
图表 3： 原始和改进因子的 IC 值分析和分层回测结果汇总 .....	5
图表 4： 改进因子的分层组合相对净值.....	5
图表 5： 改进因子的累计 RankIC.....	5
图表 6： 等量 K 线构建方法.....	6
图表 7： Transformer 模型完整网络结构.....	7
图表 8： Transformer 模型及数据细节 .....	7
图表 9： 使用不同特征集训练因子的 IC 值分析和分层回测结果汇总.....	8
图表 10： 使用不同特征集训练因子的 TOP 组合相对净值.....	8
图表 11： 使用不同特征集训练因子的累计 RankIC.....	8
图表 12： 使用 GPT 特征集训练因子的分层组合相对净值.....	8
图表 13： 中证 1000 增强组合构建细节 .....	9
图表 14： 使用不同特征集训练因子的中证 1000 增强组合超额收益（80%成份股） .....	9
图表 15： 使用不同特征集训练因子的中证 1000 增强组合超额收益（无成份股约束） .....	9


图表 16: 使用不同特征集训练因子的中证 1000 增强组合回测绩效 .....	10
图表 17: 使用不同特征集训练因子的中证 1000 增强组合逐年收益率 .....	10
图表 18: 使用不同特征集训练因子间的相关性 .....	10
图表 19: 使用不同特征集训练因子与常见风险因子的相关性 .....	10
图表 20: Transformer 与 iTransformer 对比 .....	11
图表 21: iTransformer 模型网络结构 .....	11
图表 22: Crossformer 模型网络结构 .....	12
图表 23: iTransformer 模型细节 .....	12
图表 24: Crossformer 模型细节 .....	12
图表 25: 使用不同模型训练因子的 IC 值分析和分层回测结果汇总 .....	12
图表 26: 使用不同模型训练因子的 TOP 组合相对净值 .....	13
图表 27: 使用不同模型训练因子的累计 RankIC .....	13
图表 28: 使用复合模型训练因子的分层组合相对净值 .....	13
图表 29: 使用不同模型训练因子的中证 1000 增强组合超额收益（80%成份股） .....	14
图表 30: 使用不同模型训练因子的中证 1000 增强组合超额收益（无成份股约束） .....	14
图表 31: 使用不同模型训练因子的中证 1000 增强组合回测绩效 .....	14
图表 32: 使用不同模型训练因子的中证 1000 增强组合逐年收益率 .....	15
图表 33: 使用不同模型训练因子间的相关性 .....	15
图表 34: 使用不同模型训练因子与常见风险因子的相关性 .....	15
图表 35: 收益序列预测模型网络结构 .....	16
图表 36: Transformer 收益序列预测模型及数据细节 .....	16
图表 37: 不同预测周期的 RankIC .....	17
图表 38: 使用不同预测目标训练因子的 IC 值分析和分层回测结果汇总 .....	17
图表 39: 使用不同预测目标训练因子的 TOP 组合相对净值 .....	17
图表 40: 使用不同预测目标训练因子的累计 RankIC .....	17
图表 41: 使用不同预测目标训练因子的中证 1000 增强组合超额收益（80%成份股） .....	18
图表 42: 使用不同预测目标训练因子的中证 1000 增强组合超额收益（无成份股约束） .....	18
图表 43: 使用不同预测目标训练因子的中证 1000 增强组合回测绩效 .....	19
图表 44: 使用不同预测目标训练因子的中证 1000 增强组合逐年收益率 .....	19
图表 45: 使用不同预测目标训练因子间的相关性 .....	19
图表 46: 使用不同预测目标训练因子与常见风险因子的相关性 .....	19

## 研究导读

随着市场微观结构研究的深入，高频量价数据在量化投资中的重要性日益凸显。高频数据包含了丰富的市场信息，能够为选股策略提供更精准的信号。然而，传统的人工挖掘因子和简单模型方法难以充分捕捉高频数据中的复杂规律。因此，如何更有效地利用高频数据，成为量化投资领域的重要研究方向。

在前期研究《基于全频段量价特征的选股模型》(2023-12-8)中，我们构建了一个基于 GRU 的高频深度学习模型。利用分钟线、逐笔成交和逐笔委托数据，先人工构建了 27 个高频因子，再通过 GRU 网络对这些因子进行合成，预测未来 10 日总收益。测试结果表明，该模型在 RankIC、多头收益等指标上表现显著优于等权和 ICIR 加权合成方法。然而，随着市场环境的变化和技术的发展，该模型仍有进一步优化的空间。

图表1：基于 GRU 的高频因子模型

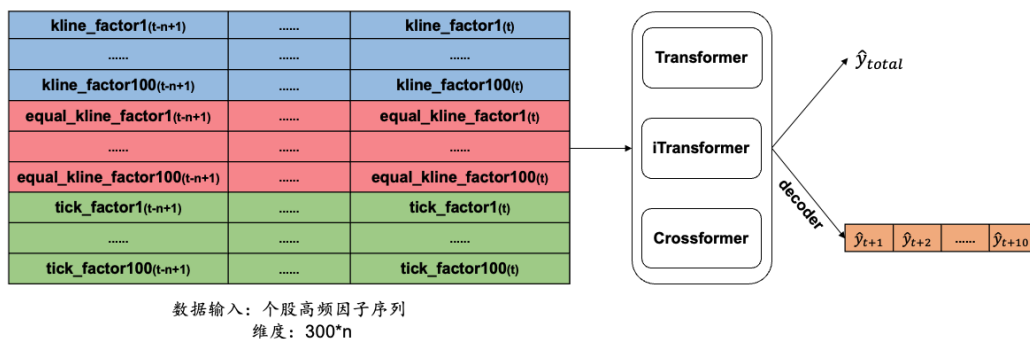


资料来源：华泰研究

近年来，大语言模型引领了科技界和产业界的技术变革，不仅为数学、化学、物理、生物等多个领域的科学研究提供了重要支持，而且验证了 Transformer 架构显著优于传统序列神经网络的性能。受此启发，本文将从因子端、模型端、标签端三个角度，提出对高频量价模型的改进方案：

- (1) 在因子端引入大语言模型生成的分钟线、等量 K 线和 tick 因子，以更全面地捕捉市场信息；
- (2) 在模型端采用 Transformer 架构，并借鉴 iTransformer 和 Crossformer 模型，通过引入变量间注意力机制，提升对高频数据的表征能力；
- (3) 在标签端将预测目标从未来 10 日总收益调整为未来 10 日逐日收益序列，以提供更细粒度的投资信号。

图表2：多角度改进高频因子模型



资料来源：华泰研究


实证结果表明，因子端和模型端的改进方案均能提升选股效果，而标签端的改进方案在目前单周期组合优化的框架下并无优势，可能需要探索更适用的场景。

图表3：原始和改进因子的IC值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
原始因子	8.64%	7.81%	1.11	86.62%	18.46%	3.32	76.53%	102.41%
改进因子	11.64%	10.04%	1.16	88.89%	25.94%	3.81	85.71%	87.68%


注：回测期为 2017/1/1~2025/2/28，周频调仓，计算 RankIC 采用 T+1~T+6 收盘价收益率，分 10 层，换手率为双边  
资料来源：Wind，华泰研究

图表4：改进因子的分层组合相对净值



资料来源：Wind，华泰研究

图表5：改进因子的累计 RankIC



资料来源：Wind，华泰研究



## 因子端：引入大语言模型生成因子

### 因子构建

在高频量价模型的构建中，因子的质量和多样性直接影响模型的预测能力。传统的人工挖掘因子方法虽然能够捕捉部分市场信息，但可能存在一定的局限性。随着大模型技术的快速发展，利用大语言模型生成因子成为因子挖掘的重要方向。前期报告《GPT 因子工厂：多智能体与因子挖掘》（2024-2-20）和《GPT 因子工厂 2.0：基本面与高频因子挖掘》（2024-9-26），已展现出大语言模型对日频量价、分钟频量价和基本面数据的信息挖掘能力。本文基于分钟线、等量 K 线和 tick 数据，引入大模型生成的特征，以捕捉更丰富的市场微观信息。


分钟线数据包括股票每分钟的开盘价、最高价、最低价、收盘价、成交金额、成交量、成交笔数等数据。基于分钟线数据，利用大语言模型生成 100 个因子，以刻画股票日内收益、价格波动、成交分布、量价相关性等特征，具体构建方法参考《GPT 因子工厂 2.0：基本面与高频因子挖掘》（2024-9-26）。

等量 K 线是一种基于成交量而非时间划分的 K 线构建方法，其定义是将一定数量的成交量作为一根 K 线的单位，本研究的构建方法如下：

- （1）计算每只股票过去  $n$  个交易日的总成交量，除以设定的 K 线数量  $\text{bar\_num}$ ，得到每根等量 K 线的成交量；
- （2）按照时间顺序遍历 1 分钟 K 线，当累计成交量达到等量 K 线成交量的倍数时，生成 1 根等量 K 线，记录其开盘价、最高价、最低价、收盘价、成交量加权均价。

与传统的分钟 K 线相比，等量 K 线能够更准确地反映市场的真实交易行为，尤其是在成交量分布不均匀的情况下。基于等量 K 线的价格数据，同样利用大语言模型生成 100 个因子，反映股票在均匀成交量下的价格趋势、价格波动、收益分布等特征。

图表6：等量 K 线构建方法



资料来源：华泰研究

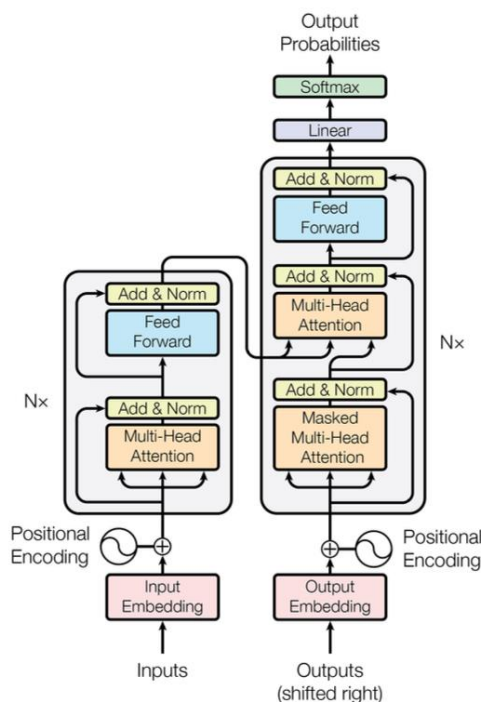
相比于分钟线数据，tick 数据更新频率更高（每 3 秒更新一次），包括 10 个档位的买入价、买入量、买入笔数、卖出量、卖出价、卖出笔数等信息。我们额外引入了一些针对性的算子，如档位求和、档位求差等。最后再利用大语言模型生成 100 个因子，捕捉股票流动性、订单不平衡等特征。

本研究使用的大语言模型为 OpenAI 开发的 o1-preview，其训练截止日期为 2024-09-12，此后视为严格的样本外时段。

### 因子训练

为验证和比较不同类型因子的有效性，初步使用 Transformer 进行因子合成训练。Transformer 完整架构包括 encoder 和 decoder，这里仅使用 encoder 来表征因子数据，最后通过全连接层输出对未来 10 日收益的预测。模型网络结构和数据细节如下。

图表7：Transformer 模型完整网络结构



资料来源：Attention is all you need，华泰研究

图表8：Transformer 模型及数据细节

特征和标签	特征 X: 个股过去 40 个交易日的高频因子数据。
	标签 y: 个股未来 10 个交易日 (T+1~T+11) 的收益率。
	样本内训练数据从 2013 年开始，每 5 个交易日采样一次，训练集和验证集依时间先后按照 4:1 的比例划分。
模型结构	Input Embedding: 输入嵌入。
	Positional Encoding: 位置编码。
	Multi-Head Attention: 多头注意力。
	Feed Forward: 全连接。
	Encoder: 每层包括多头注意力、全连接、残差连接、层标准化等。
	FC: 全连接，输出预测。
	损失函数: 预测值与标签之间 IC 的相反数。

资料来源：华泰研究

## 因子测试

为了减轻随机性干扰，本文的深度学习模型都用不同随机数种子训练三次，将三次的模型等权集成，作为最终的因子信号进行回测。因子测试方法如下：

1. 股票池：全 A 股，剔除 ST 股票，剔除每个截面期下一交易日停牌、涨停的股票。
2. 回测区间：2017/1/1~2025/2/28。
3. 调仓周期：周频，不计交易费用。
4. 测试方法：IC 值分析，因子分 10 层测试。

相比于人工特征集，基于不同类型 GPT 特征集训练的深度学习因子，在 RankIC 均值、TOP 组合年化超额收益率、TOP 组合胜率等多项指标上均表现更优，同时 TOP 组合换手率有所降低。将三类 GPT 特征集合并后训练的因子，综合表现进一步提升。

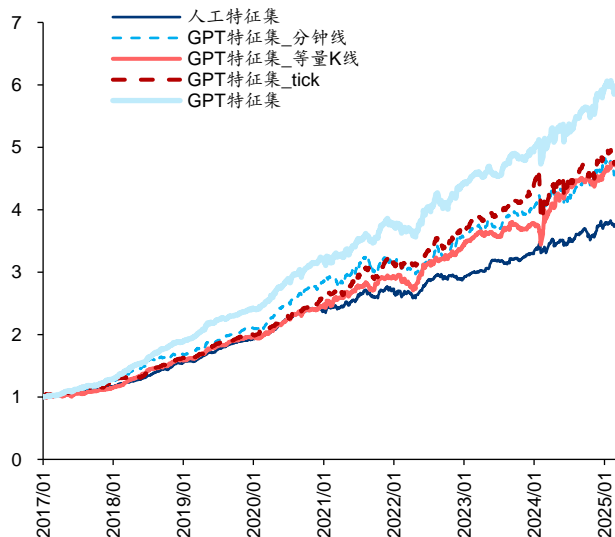
图表9：使用不同特征集训练因子的 IC 值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
人工特征集	8.64%	7.81%	1.11	86.62%	18.46%	3.32	76.53%	102.41%
GPT 特征集_分钟线	10.44%	10.37%	1.01	84.85%	21.38%	2.90	79.59%	85.13%
GPT 特征集_等量 K 线	9.59%	9.90%	0.97	83.84%	22.19%	3.02	82.65%	100.14%
GPT 特征集_tick	9.57%	11.11%	0.86	82.83%	21.89%	2.96	80.61%	77.35%
GPT 特征集	11.18%	9.98%	1.12	88.38%	25.51%	3.48	85.71%	88.73%

注：回测期为 2017/1/1~2025/2/28，周频调仓，计算 RankIC 采用 T+1~T+6 收盘价收益率，分 10 层，换手率为双边

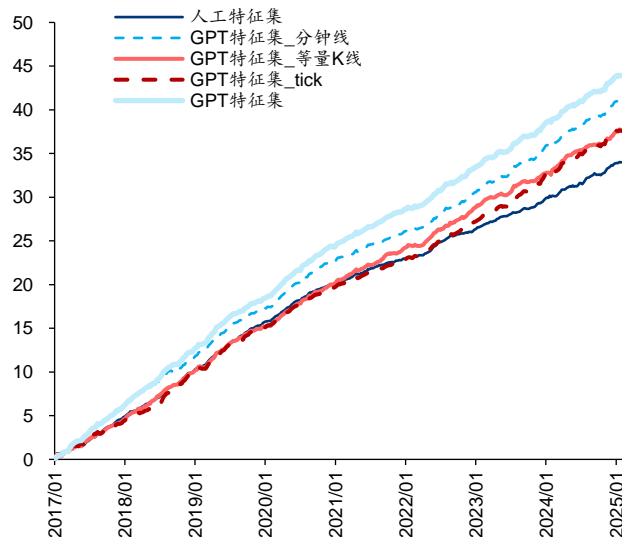
资料来源：Wind，华泰研究

图表10：使用不同特征集训练因子的 TOP 组合相对净值




资料来源：Wind，华泰研究

图表11：使用不同特征集训练因子的累计 RankIC



资料来源：Wind，华泰研究

图表12：使用 GPT 特征集训练因子的分层组合相对净值



注：回测期为 2017/1/1~2025/2/28

资料来源：Wind，华泰研究

## 指增测试

中证 1000 增强测试方法如下，其中成份股权重约束考虑不低于 80%、无约束两种场景。




图表13：中证 1000 增强组合构建细节

优化目标	最大化预期收益
成份股权重约束	场景 1：不低于 80%；场景 2：无约束
个股权重偏离上限	0.8%
风格因子约束	行业暴露<0.02, barra 暴露<0.3
换手率约束	周双边换手率上限为 30%
调仓频率和交易成本	周频调仓，调仓当日以 vwap 价格成交，交易成本双边千分之四

资料来源：华泰研究

在两种场景下，GPT 合并特征集训练出的因子所构建的增强组合收益表现都明显优于人工特征集。近两年，80%成份股约束下中证 1000 增强的超额收益出现衰减的迹象，可能是因为随着中证 1000 增强产品数量和规模增长，成份股内的 alpha 竞争加剧。解除 80%成份股限制后，超额收益有所提升，不过也会放大跟踪误差和超额最大回撤。


图表14：使用不同特征集训练因子的中证 1000 增强组合超额收益（80%成份股）



注：回溯期为 2017/1/1~2025/2/28

资料来源：Wind，华泰研究

图表15：使用不同特征集训练因子的中证 1000 增强组合超额收益（无成份股约束）



注：回溯期为 2017/1/1~2025/2/28

资料来源：Wind，华泰研究

图表16：使用不同特征集训练因子的中证1000增强组合回测绩效

	年化收益率	年化波动率	夏普比率	最大回撤	年化超额收	年化跟踪误	超额收益最	信息比率	Calmar 比率	相对基准月	调仓双边换
					益率	差	大回撤			胜率	手率
80%成份股											
人工特征集	10.82%	24.31%	0.44	33.99%	15.40%	5.00%	9.03%	3.08	1.71	80.61%	34.30%
GPT 特征集_分钟线	12.63%	25.08%	0.50	34.65%	17.46%	5.63%	5.49%	3.10	3.18	81.63%	34.50%
GPT 特征集_等量K线	9.48%	25.07%	0.38	39.50%	14.14%	6.14%	6.14%	2.30	2.30	77.55%	34.37%
GPT 特征集_tick	10.11%	23.92%	0.42	38.42%	14.53%	5.32%	6.36%	2.73	2.29	78.57%	34.12%
GPT 特征集	14.20%	25.04%	0.57	36.52%	19.08%	5.86%	5.60%	3.26	3.40	83.67%	34.47%
无成份股约束											
人工特征集	11.82%	24.16%	0.49	34.20%	16.35%	5.74%	7.99%	2.85	2.05	81.63%	34.37%
GPT 特征集_分钟线	12.55%	25.45%	0.49	38.83%	17.36%	7.32%	8.75%	2.37	1.98	76.53%	34.60%
GPT 特征集_等量K线	12.16%	25.49%	0.48	35.16%	16.95%	7.61%	9.60%	2.23	1.76	76.53%	34.64%
GPT 特征集_tick	12.44%	24.27%	0.51	35.66%	16.96%	6.60%	10.08%	2.57	1.68	80.61%	34.33%
GPT 特征集	15.73%	25.40%	0.62	35.09%	20.67%	7.34%	9.29%	2.81	2.22	78.57%	34.66%
中证1000	-4.05%	24.12%	-0.17	52.14%							

注：回测期为2017/1/1~2025/2/28

资料来源：Wind，华泰研究

图表17：使用不同特征集训练因子的中证1000增强组合逐年收益率

	2017 年收益率	2018 年收益率	2019 年收益率	2020 年收益率	2021 年收益率	2022 年收益率	2023 年收益率	2024 年收益率	2025 年收益率
80%成份股									
人工特征集	-5.14%	-22.23%	53.42%	38.49%	32.00%	-8.82%	3.18%	7.57%	6.90%
GPT 特征集_分钟线	2.72%	-17.94%	49.70%	42.51%	38.79%	-11.81%	2.49%	7.14%	5.16%
GPT 特征集_等量K线	-8.72%	-15.02%	45.93%	28.56%	41.93%	-7.68%	-1.45%	3.47%	4.67%
GPT 特征集_tick	-7.29%	-23.07%	53.72%	40.95%	32.73%	-9.22%	3.82%	5.43%	4.43%
GPT 特征集	-1.09%	-16.82%	53.61%	44.46%	47.63%	-7.80%	2.02%	7.47%	4.04%
无成份股约束									
人工特征集	-4.00%	-22.83%	57.68%	33.14%	38.38%	-9.18%	5.98%	7.62%	7.74%
GPT 特征集_分钟线	3.50%	-16.31%	47.15%	36.32%	34.71%	-13.05%	0.88%	16.88%	5.34%
GPT 特征集_等量K线	-8.07%	-11.82%	46.76%	27.24%	35.52%	-4.89%	6.84%	10.84%	6.49%
GPT 特征集_tick	-6.22%	-21.06%	58.94%	42.80%	34.74%	-11.01%	8.74%	10.68%	3.44%
GPT 特征集	3.99%	-13.19%	56.78%	41.24%	41.81%	-7.31%	1.46%	13.73%	3.80%
中证1000	-19.06%	-36.87%	25.67%	19.39%	20.52%	-21.58%	-6.28%	1.20%	5.25%

注：回测期为2017/1/1~2025/2/28

资料来源：Wind，华泰研究

## 因子相关性分析

相关性分析显示，不同特征集训练得到的因子具有较大的差异性，不过因子普遍具有反转、小市值、低流动性、高 beta、低估值等风格暴露。

图表18：使用不同特征集训练因子间的相关性

	人工特征集	GPT 特征集_分钟线	GPT 特征集_等量K线	GPT 特征集_tick	GPT 特征集
人工特征集		0.54	0.39	0.51	0.53
GPT 特征集_分钟线	0.54		0.52	0.62	0.78
GPT 特征集_等量K线	0.39	0.52		0.45	0.62
GPT 特征集_tick	0.51	0.62	0.45		0.72
GPT 特征集	0.53	0.78	0.62	0.72	

资料来源：Wind，华泰研究

图表19：使用不同特征集训练因子与常见风险因子的相关性

	动量	市值	成交金额	换手率	beta	账面市值比
人工特征集	-0.13	-0.06	-0.31	-0.32	0.19	0.15
GPT 特征集_分钟线	-0.16	-0.03	-0.28	-0.33	0.23	0.14
GPT 特征集_等量K线	-0.23	0.01	-0.27	-0.33	0.26	0.12
GPT 特征集_tick	-0.09	-0.10	-0.38	-0.37	0.21	0.20
GPT 特征集	-0.16	-0.04	-0.29	-0.33	0.23	0.17

资料来源：Wind，华泰研究

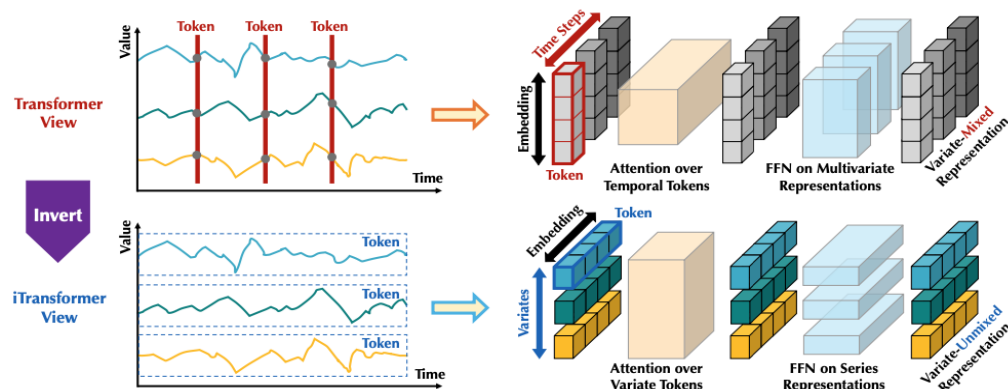
## 模型端：引入变量间注意力

### 模型介绍

Transformer 的核心机制是多头注意力，能够捕捉输入序列中不同位置间的依赖关系。注意力机制还可以迁移到其他场景，例如前期报告《Attention is indeed all you need》(2023-8-22) 展示了注意力机制在时序数据、股票间关系以及任务间关联中的应用。这说明注意力机制具有强大的泛化能力，能够灵活地建模复杂的关系。本研究将探讨如何将注意力机制应用于变量间的依赖关系，以增强对因子间交互作用的建模。

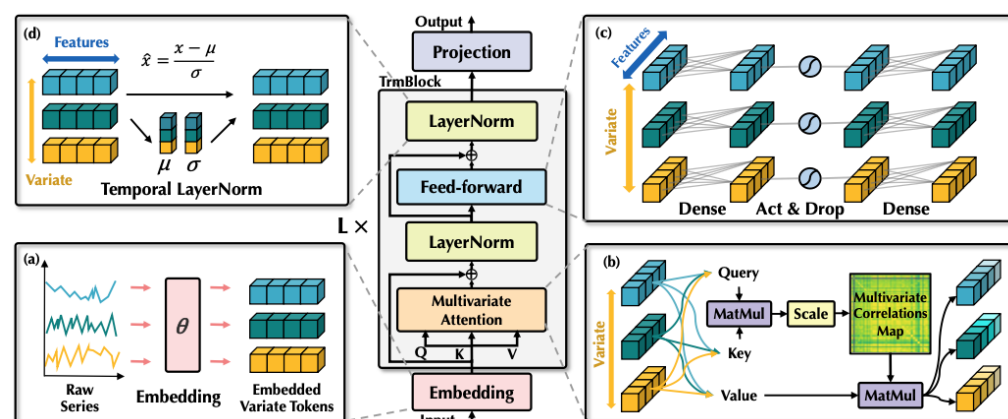
iTransformer (Inverted Transformer) 发表于 2024 年的 ICLR，其核心思想是将时间序列维度反转。具体来说，iTransformer 将每个变量的时间序列嵌入为独立的 token，并通过自注意力机制捕捉变量间的相关性，同时利用前馈网络学习每个变量的非线性表示。这种设计使得 iTransformer 能够更好地处理多变量时间序列中的复杂依赖关系，同时避免了传统 Transformer 在处理长序列时性能下降和计算爆炸的问题。实验表明，iTransformer 在多个真实世界数据集上取得了最先进的性能，展现了其在多变量时间序列预测中的强大能力。

图表20：Transformer 与 iTransformer 对比



资料来源：iTransformer: Inverted transformers are effective for time series forecasting，华泰研究

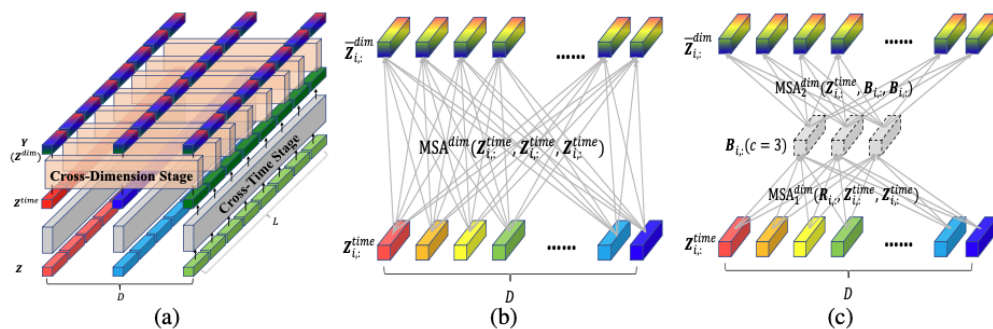
图表21：iTransformer 模型网络结构



资料来源：iTransformer: Inverted transformers are effective for time series forecasting，华泰研究

Crossformer 发表于 2023 年的 ICLR，其核心创新在于同时捕捉多变量时间序列中跨时间和跨维度的依赖关系。Crossformer 通过维度分段嵌入（Dimension-Segment-Wise Embedding）将每个变量的时间序列分段嵌入为 2D 向量数组，并通过两阶段注意力（Two-Stage Attention）机制分别捕捉时间维度和变量维度上的依赖关系。此外，Crossformer 采用分层编码器-解码器（Hierarchical Encoder-Decoder）结构，利用不同尺度的信息进行预测。这种设计使得 Crossformer 能够更高效地建模多变量时间序列中的复杂关系，并在多个真实世界数据集上取得了领先的性能。

图表22：Crossformer 模型网络结构



资料来源：Crossformer: Transformer utilizing cross-dimension dependency for multivariate time series forecasting，华泰研究

本研究继续以前文 GPT 特征集的 300 个因子为例，测试 iTransformer 和 Crossformer 的选股效果，并与 Transformer 进行对比。iTransformer 和 Crossformer 的模型细节如下。

图表23：iTransformer 模型细节

## 模型结构

- Input Embedding：输入嵌入，用于时间维度。
- Multi-Head Attention：多头注意力，用于变量维度。
- Feed Forward：全连接。
- Encoder：每层包括多头注意力、全连接、残差连接、层标准化等。
- FC：全连接，输出预测。
- 损失函数：预测值与标签之间 IC 的相反数。

资料来源：华泰研究

图表24：Crossformer 模型细节

## 模型结构

- Dimension-Segment-Wise Embedding：维度分段嵌入。
- Multi-Head Attention：多头注意力。
- Feed Forward：全连接。
- Cross-Time Stage：时间注意力阶段，每层包括多头注意力、全连接、残差连接、层标准化等。
- Cross-Dimension Stage：变量注意力阶段，每层包括多头注意力、全连接、残差连接、层标准化等。
- FC：全连接，输出预测。
- 损失函数：预测值与标签之间 IC 的相反数。

资料来源：华泰研究

## 因子测试

相比于 Transformer 模型，iTransformer 模型的 RankIC 均值和 TOP 组合年化超额收益率略低，但 RankICIR 和 TOP 组合信息比率更高；Crossformer 模型的 RankIC 均值、RankICIR 和 TOP 组合信息比率更优。将三类模型复合后得到的因子，RankIC 均值和 TOP 组合年化超额收益率进一步提升。


图表25：使用不同模型训练因子的 IC 值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
Transformer	11.18%	9.98%	1.12	88.38%	25.51%	3.48	85.71%	88.73%
iTransformer	11.12%	9.76%	1.14	88.38%	23.42%	3.83	87.76%	94.26%
Crossformer	11.29%	9.54%	1.18	88.64%	24.82%	3.92	86.74%	90.54%
复合模型	11.64%	10.04%	1.16	88.89%	25.94%	3.81	85.71%	87.68%

注：回测期为 2017/1/1~2025/2/28，周频调仓，计算 RankIC 采用 T+1~T+6 收盘价收益率，分 10 层，换手率为双边

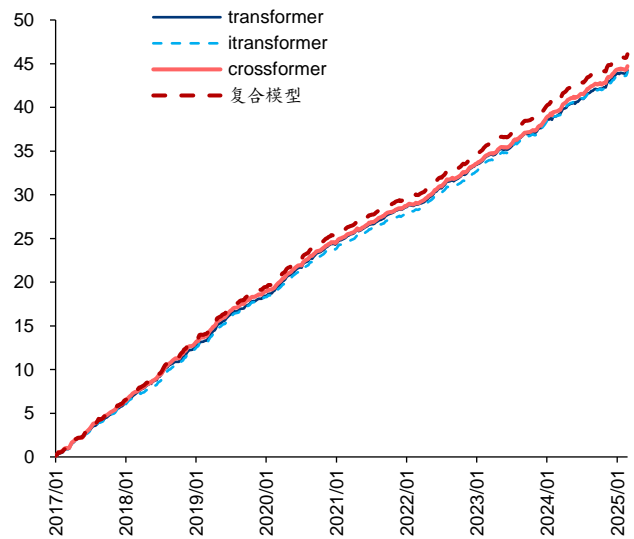
资料来源：Wind，华泰研究

图表26：使用不同模型训练因子的 TOP 组合相对净值



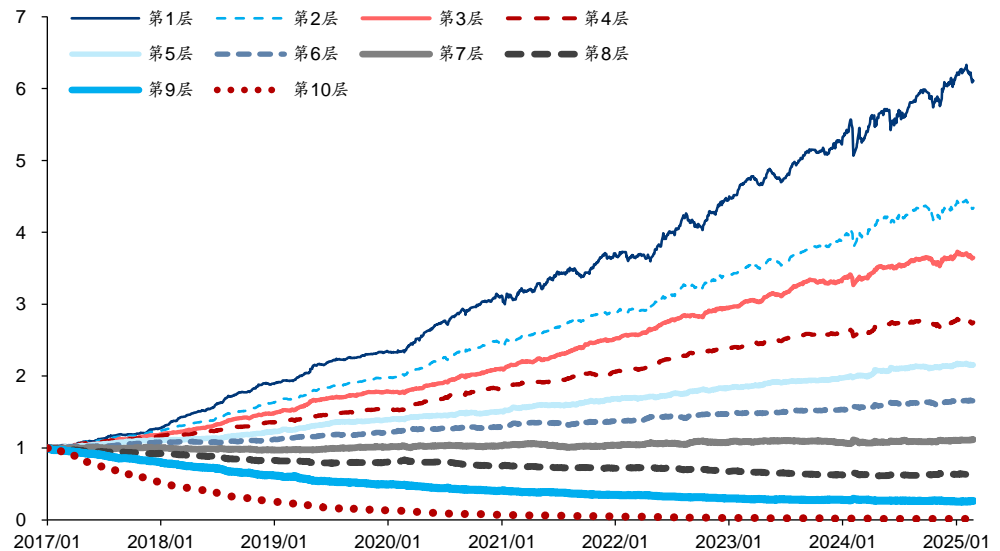
资料来源：Wind，华泰研究

图表27：使用不同模型训练因子的累计 RankIC



资料来源：Wind，华泰研究

图表28：使用复合模型训练因子的分层组合相对净值



注：回溯期为 2017/1/1~2025/2/28


资料来源：Wind，华泰研究

### 指增测试

在指增测试中, iTransformer 模型和 Crossformer 模型的信息比率均高于 Transformer 模型, 复合模型的超额收益表现最优。




图表29：使用不同模型训练因子的中证1000增强组合超额收益（80%成份股）



注：回溯期为 2017/1/1~2025/2/28

资料来源：Wind，华泰研究

图表30：使用不同模型训练因子的中证1000增强组合超额收益（无成份股约束）



注：回溯期为 2017/1/1~2025/2/28

资料来源：Wind，华泰研究

图表31：使用不同模型训练因子的中证1000增强组合回溯绩效

	年化收益率	年化波动率	夏普比率	最大回撤	年化超额收 益率	年化跟踪误 差	超额收益最 大回撤	信息比率Calmar 比率	相对基准月 胜率	调仓双边换 手率
80%成份股										
Transformer	14.20%	25.04%	0.57	36.52%	19.08%	5.86%	5.60%	3.26	3.40	83.67%
iTransformer	14.16%	24.32%	0.58	35.71%	18.85%	5.53%	5.62%	3.41	3.35	83.67%
Crossformer	14.63%	24.52%	0.60	33.55%	19.40%	5.36%	6.14%	3.62	3.16	85.71%
复合模型	15.42%	24.65%	0.63	34.07%	20.25%	5.62%	5.26%	3.60	3.85	83.67%
无成份股约束										
Transformer	15.73%	25.40%	0.62	35.09%	20.67%	7.34%	9.29%	2.81	2.22	78.57%
iTransformer	14.56%	24.31%	0.60	33.72%	19.20%	6.41%	7.35%	3.00	2.61	79.59%
Crossformer	14.35%	24.55%	0.58	34.48%	19.06%	6.31%	7.29%	3.02	2.61	80.61%
复合模型	16.49%	24.73%	0.67	33.08%	21.31%	6.69%	9.26%	3.18	2.30	82.65%
中证1000	-4.05%	24.12%	-0.17	52.14%						

注：回溯期为 2017/1/1~2025/2/28

资料来源：Wind，华泰研究

图表32：使用不同模型训练因子的中证 1000 增强组合逐年收益率

	2017 年收益率	2018 年收益率	2019 年收益率	2020 年收益率	2021 年收益率	2022 年收益率	2023 年收益率	2024 年收益率	2025 年收益率
80%成份股									
Transformer	-1.09%	-16.82%	53.61%	44.46%	47.63%	-7.80%	2.02%	7.47%	4.04%
iTransformer	-1.96%	-14.20%	50.25%	46.98%	45.07%	-7.90%	0.63%	8.68%	4.12%
Crossformer	-0.99%	-17.66%	53.18%	40.27%	46.84%	-5.96%	2.74%	14.44%	2.60%
复合模型	-0.82%	-12.62%	54.01%	47.50%	41.86%	-5.95%	3.99%	8.56%	3.88%
无成份股约束									
Transformer	3.99%	-13.19%	56.78%	41.24%	41.81%	-7.31%	1.46%	13.73%	3.80%
iTransformer	-2.01%	-11.17%	53.71%	38.42%	38.10%	-10.11%	7.40%	12.33%	4.75%
Crossformer	-0.49%	-17.25%	53.68%	39.38%	40.77%	-6.41%	4.47%	14.85%	2.73%
复合模型	2.77%	-10.96%	52.01%	42.79%	42.21%	-8.61%	5.10%	16.26%	5.00%
中证 1000	-19.06%	-36.87%	25.67%	19.39%	20.52%	-21.58%	-6.28%	1.20%	5.25%

注：回测期为 2017/1/1~2025/2/28

资料来源：Wind，华泰研究

## 因子相关性分析

不同模型训练出的因子具有较高的相关性。

图表33：使用不同模型训练因子间的相关性

	Transformer	iTransformer	Crossformer	复合模型
Transformer		0.80	0.82	0.93
iTransformer	0.80		0.89	0.95
Crossformer	0.82	0.89		0.95
复合模型	0.93	0.95	0.95	

资料来源：Wind，华泰研究

图表34：使用不同模型训练因子与常见风险因子的相关性

	动量	市值	成交金额	换手率	beta	账面市值比
Transformer	-0.16	-0.04	-0.29	-0.33	0.23	0.17
iTransformer	-0.18	-0.03	-0.33	-0.38	0.25	0.21
Crossformer	-0.16	-0.02	-0.30	-0.35	0.25	0.21
复合模型	-0.17	-0.03	-0.32	-0.37	0.25	0.20

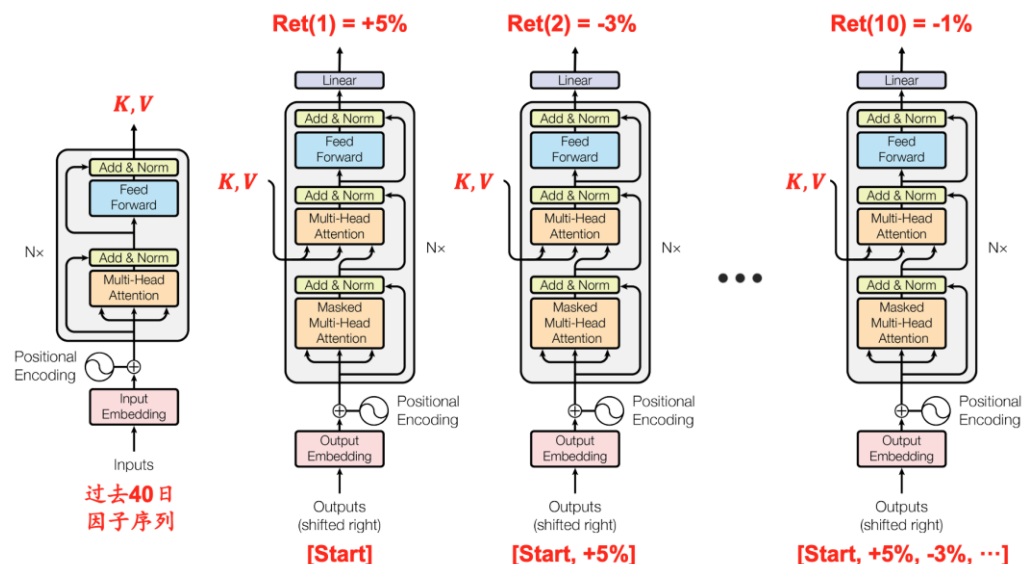
资料来源：Wind，华泰研究

## 标签端：引入收益序列预测

此前的深度学习选股模型，通常是将来一段时间的总收益作为预测目标，很少对收益率序列展开预测，比如逐日收益。与直接预测总收益相比，预测逐日收益序列可能具有以下优势：第一，逐日预测能够更好地捕捉市场短期波动特征，提供更细粒度的投资信号，从而帮助投资者理解市场动态并制定灵活的决策策略。第二，逐日预测能够充分利用更高信息密度的标签数据，提升模型的训练效果。

收益序列预测类似于机器翻译，是一种“序列到序列”任务 (seq2seq)，即输入因子序列，输出收益序列。此场景下，Transformer 的 decoder 模块可以发挥重要作用。相比于 encoder，decoder 有两处关键改动：一是加入掩码多头注意力，学习目标序列间的依赖性，掩码的目的是避免未来信息泄露；二是通过多头注意力学习输入序列和目标序列间的关联。此外，decoder 在训练和推理阶段也有所差异：例如预测  $T+5 \sim T+6$  的收益，训练阶段可以使用  $T \sim T+5$  的真实收益序列辅助训练，而推理阶段采用自回归生成机制，即以  $T \sim T+5$  的预测收益序列作为输入，生成下一时刻的预测，再以此类推，这样能够保证  $T$  时刻在不使用任何未来信息前提下输出  $T \sim T+10$  的收益序列。

图表35：收益序列预测模型网络结构



资料来源：Attention is all you need，华泰研究

以 Transformer 为例，收益序列预测模型的细节如下。

图表36：Transformer 收益序列预测模型及数据细节


特征和标签	特征 X: 个股过去 40 个交易日的高频因子数据。
	标签 y: 个股未来 10 个交易日 ( $T \sim T+10$ ) 的逐日收益率序列。
	样本内训练数据从 2013 年开始，每 5 个交易日采样一次，训练集和验证集依时间先后按照 4:1 的比例划分。
模型结构	Input Embedding: 输入嵌入。
	Positional Encoding: 位置编码。
	Multi-Head Attention: 多头注意力。
	Feed Forward: 全连接。
	Masked Multi-Head Attention: 掩码多头注意力。
	Encoder: 每层包括多头注意力、全连接、残差连接、层标准化等。
	Decoder: 每层包括掩码多头注意力、多头注意力、全连接、残差连接、层标准化等，输出序列预测。
	损失函数: 预测值与标签之间 IC 的相反数。

资料来源：华泰研究

## 因子测试

以某个随机数种子训练的 Transformer 收益序列预测模型为例，比较不同周期的预测性能。结果表明，随着预测周期的拉长，单日预测的 RankIC 逐渐下降，而累计预测的 RankIC 逐渐提高。这一现象的原因在于：短期收益受噪声影响较大，随着预测周期的拉长，噪声的累积使得单日预测的不确定性增加；而长期累计收益能够平滑噪声的影响，随着预测周期的拉长，累计收益的不确定性降低。

图表37：不同预测周期的 RankIC



注：回溯期为 2017/1/1~2025/2/28，计算单日预测 RankIC 采用  $T+1 \sim T+i$  收盘价收益率，计算累计预测 RankIC 采用  $T \sim T+i$  收盘价收益率

资料来源：Wind，华泰研究

为了与前文模型进行对比，我们基于 Transformer、iTransformer 和 Crossformer 分别训练收益序列预测模型，再等权合成，最后将序列简单求和后进行单因子测试。该因子虽然具有一定的选股能力，但效果不及传统的总收益预测模型，这可能是由于不同时间点的预测性能存在差异，一般来说时间靠前的交易日包含更重要的信息，预测效果要好于时间靠后的交易日，简单求和会损失这些信息。


图表38：使用不同预测目标训练因子的 IC 值分析和分层回测结果汇总

	RankIC 均值	RankIC 标准差	RankICIR	RankIC>0 占比	TOP 组合年化超额收益率	TOP 组合信息比率	TOP 组合胜率	TOP 组合换手率
总收益预测	11.64%	10.04%	1.16	88.89%	25.94%	3.81	85.71%	87.68%
收益序列预测	11.25%	9.34%	1.20	88.13%	21.69%	3.45	81.63%	106.62%
复合预测	11.74%	9.80%	1.20	88.64%	23.99%	3.63	81.63%	94.92%

注：回溯期为 2017/1/1~2025/2/28，周频调仓，计算 RankIC 采用  $T+1 \sim T+6$  收盘价收益率，分 10 层，换手率为双边


资料来源：Wind，华泰研究

图表39：使用不同预测目标训练因子的 TOP 组合相对净值



资料来源：Wind，华泰研究

图表40：使用不同预测目标训练因子的累计 RankIC




资料来源：Wind，华泰研究

## 指增测试

中证 1000 增强测试结果显示，收益序列预测模型选股效果仍然弱于总收益预测模型。不过，将两个组合等权配置，跟踪误差有所下降。综上，对收益预测序列简单求和可能不是最佳的使用途径，会造成信息损失，未来可探索多周期优化等更合适的应用场景，以充分发挥收益序列预测的优势。


图表41：使用不同预测目标训练因子的中证 1000 增强组合超额收益（80%成份股）



注：回溯期为 2017/1/1~2025/2/28

资料来源：Wind，华泰研究

图表42：使用不同预测目标训练因子的中证 1000 增强组合超额收益（无成份股约束）



注：回溯期为 2017/1/1~2025/2/28

资料来源：Wind，华泰研究



图表43：使用不同预测目标训练因子的中证1000增强组合回测绩效

	年化收益率	年化波动率	夏普比率	最大回撤	年化超额收益率	年化跟踪误差	超额收益最大回撤	信息比率	Calmar比率	相对基准月胜率	调仓双边换手率
					益率	差	大回撤			胜率	手率
					80%成份股						
总收益预测	15.42%	24.65%	0.63	34.07%	20.25%	5.62%	5.26%	3.60	3.85	83.67%	34.32%
收益序列预测	13.69%	24.73%	0.55	34.94%	18.47%	5.65%	6.58%	3.27	2.81	86.73%	34.24%
复合预测	14.59%	24.63%	0.59	34.47%	19.39%	5.39%	5.54%	3.60	3.50	86.73%	34.05%
					无成份股约束						
总收益预测	16.49%	24.73%	0.67	33.08%	21.31%	6.69%	9.26%	3.18	2.30	82.65%	34.48%
收益序列预测	14.03%	25.10%	0.56	37.07%	18.83%	6.92%	11.45%	2.72	1.64	77.55%	34.37%
复合预测	15.31%	24.84%	0.62	34.93%	20.13%	6.53%	10.24%	3.08	1.97	79.59%	34.22%
中证1000	-4.05%	24.12%	-0.17	52.14%							

注：回测期为2017/1/1~2025/2/28

资料来源：Wind，华泰研究

图表44：使用不同预测目标训练因子的中证1000增强组合逐年收益率

	2017年收益率	2018年收益率	2019年收益率	2020年收益率	2021年收益率	2022年收益率	2023年收益率	2024年收益率	2025年收益率
总收益预测	-0.82%	-12.62%	54.01%	47.50%	41.86%	-5.95%	3.99%	8.56%	3.88%
收益序列预测	3.87%	-19.32%	48.06%	45.93%	41.14%	-3.82%	1.74%	7.03%	2.23%
复合预测	1.50%	-16.02%	51.04%	46.77%	41.57%	-4.85%	2.88%	7.82%	3.05%
总收益预测	2.77%	-10.96%	52.01%	42.79%	42.21%	-8.61%	5.10%	16.26%	5.00%
收益序列预测	1.25%	-14.58%	50.81%	40.07%	36.04%	-9.33%	8.28%	10.84%	3.55%
复合预测	2.03%	-12.74%	51.54%	41.51%	39.17%	-8.93%	6.71%	13.56%	4.27%
中证1000	-19.06%	-36.87%	25.67%	19.39%	20.52%	-21.58%	-6.28%	1.20%	5.25%

注：回测期为2017/1/1~2025/2/28

资料来源：Wind，华泰研究

## 因子相关性分析

因子相关性分析结果如下。

图表45：使用不同预测目标训练因子间的相关性

	总收益预测	收益序列预测	复合预测
总收益预测		0.87	0.96
收益序列预测	0.87		0.97
复合预测	0.96	0.97	

资料来源：Wind，华泰研究

图表46：使用不同预测目标训练因子与常见风险因子的相关性

	动量	市值	成交金额	换手率	beta	账面市值比
总收益预测	-0.17	-0.03	-0.32	-0.37	0.25	0.20
收益序列预测	-0.17	-0.05	-0.30	-0.31	0.24	0.17
复合预测	-0.18	-0.04	-0.31	-0.34	0.25	0.19

资料来源：Wind，华泰研究

## 总结

随着市场微观结构研究的深入，高频量价数据在量化投资中的重要性日益凸显。传统的人工挖掘因子和简单模型方法难以充分捕捉高频数据中的复杂规律。本文从因子端、模型端、标签端三个角度，探讨对前期高频量价模型的改进：在因子端引入大语言模型生成的分钟线、等量 K 线和 tick 因子，以更全面地捕捉市场信息；在模型端采用 Transformer 架构，并借鉴 iTransformer 和 Crossformer 模型，通过引入变量间注意力机制，提升对高频数据的表征能力；在标签端将预测目标从未来 10 日总收益调整为未来 10 日逐日收益序列，以提供更细粒度的投资信号。

改进方向一：引入大语言模型生成因子。我们利用大语言模型，分别基于分钟线、等量 K 线和 tick 数据各生成 100 个因子。其中，分钟线因子刻画了股票日内收益、价格波动、成交分布、量价相关性等特征；等量 K 线因子反映了股票在均匀成交量下的价格趋势、价格波动、收益分布等特征；tick 因子则捕捉了股票流动性、订单不平衡等特征。实证结果表明，相比于人工特征集，基于 GPT 特征集训练的深度学习因子在多个指标上表现更优，2017 年初至 2025 年 2 月底的周度 RankIC 达 11.18%，全 A 多头年化超额收益为 25.51%，在 80% 成份股和无成份股约束场景下构建中证 1000 指数增强组合，年化超额收益分别达到 19.08% 和 20.67%，信息比率分别为 3.26 和 2.81。

改进方向二：引入变量间注意力。Transformer 通过多头注意力捕捉输入序列中不同位置间的依赖关系；iTransformer 创新性地将时间序列维度反转，通过自注意力机制捕捉变量间的相关性；Crossformer 则通过两阶段注意力机制，同时捕捉多变量时间序列中跨时间和跨维度的复杂关系。回测结果显示，iTransformer 和 Crossformer 训练得到的因子在 RankICIR 和多头信息比率上均优于传统 Transformer 模型。三类模型集成后的复合因子表现更为突出，周度 RankIC 提升至 11.64%，全 A 多头年化超额收益达 25.94%，中证 1000 指数增强组合在 80% 成份股和无成份股约束场景下的年化超额收益分别达到 20.25% 和 21.31%，信息比率分别为 3.60 和 3.18。

改进方向三：引入收益序列预测。与直接预测总收益相比，逐日收益序列预测能够更好地捕捉市场短期波动特征，提供更细粒度的投资信号，同时充分利用了更高信息密度的标签数据。在收益序列预测场景中，Transformer 的 decoder 模块通过掩码多头注意力机制，在避免未来信息泄露的前提下学习目标序列间的依赖性，并通过多头注意力学习输入序列和目标序列之间的关联。测试结果表明，decoder 能够相对有效预测未来 10 日的逐日收益，但简单求和的方式可能会造成信息损失，其单因子测试和指数增强效果均不及传统的总收益预测模型。未来可探索多周期优化等更合适的应用场景，以充分发挥收益序列预测的优势。

## 风险提示

大模型生成的因子在回测中存在引入未来信息的风险。高频量价模型对市场微观结构的依赖较强，未来市场变化可能导致模型失效。Transformer 架构的复杂性会带来训练和推理时间增加，以及过拟合风险。

## 参考文献

- [1] Zhao W X, Zhou K, Li J, et al. A survey of large language models[J]. arXiv preprint arXiv:2303.18223, 2023, 1(2).
- [2] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [3] Liu Y, Hu T, Zhang H, et al. itransformer: Inverted transformers are effective for time series forecasting[J]. arXiv preprint arXiv:2310.06625, 2023.
- [4] Zhang Y, Yan J. Crossformer: Transformer utilizing cross-dimension dependency for multivariate time series forecasting[C]//The eleventh international conference on learning representations. 2023.

## 免责声明

### 分析师声明

本人，林晓明、何康，兹证明本报告所表达的观点准确地反映了分析师对标的证券或发行人的个人意见；彼以往、现在或未来并无就其研究报告所提供的具体建议或所表达的意见直接或间接收取任何报酬。

### 一般声明及披露

本报告由华泰证券股份有限公司（已具备中国证监会批准的证券投资咨询业务资格，以下简称“本公司”）制作。本报告所载资料是仅供接收人的严格保密资料。本报告仅供本公司及其客户和其关联机构使用。本公司不因接收人收到本报告而视其为客户。

本报告基于本公司认为可靠的、已公开的信息编制，但本公司及其关联机构（以下统称为“华泰”）对该等信息的准确性及完整性不作任何保证。

本报告所载的意见、评估及预测仅反映报告发布当日的观点和判断。在不同时期，华泰可能会发出与本报告所载意见、评估及预测不一致的研究报告。同时，本报告所指的证券或投资标的的价格、价值及投资收入可能会波动。以往表现并不能指引未来，未来回报并不能得到保证，并存在损失本金的可能。华泰不保证本报告所含信息保持在最新状态。华泰对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本公司不是 FINRA 的注册会员，其研究分析师亦没有注册为 FINRA 的研究分析师/不具有 FINRA 分析师的注册资格。

华泰力求报告内容客观、公正，但本报告所载的观点、结论和建议仅供参考，不构成购买或出售所述证券的要约或招揽。该等观点、建议并未考虑到个别投资者的具体投资目的、财务状况以及特定需求，在任何时候均不构成对客户私人投资建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。对依据或者使用本报告所造成的一切后果，华泰及作者均不承担任何法律责任。任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现，过往的业绩表现不应作为日后回报的预示。华泰不承诺也不保证任何预示的回报会得以实现，分析中所做的预测可能是基于相应的假设，任何假设的变化可能会显著影响所预测的回报。

华泰及作者在自身所知情的范围内，与本报告所指的证券或投资标的不存在法律禁止的利害关系。在法律许可的情况下，华泰可能会持有报告中提到的公司所发行的证券头寸并进行交易，为该公司提供投资银行、财务顾问或者金融产品等相关服务或向该公司招揽业务。

华泰的销售人员、交易人员或其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。华泰没有将此意见及建议向报告所有接收者进行更新的义务。华泰的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。投资者应当考虑到华泰及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。有关该方面的具体披露请参照本报告尾部。

本报告并非意图发送、发布给在当地法律或监管规则下不允许向其发送、发布的机构或人员，也并非意图发送、发布给因可得到、使用本报告的行为而使华泰违反或受制于当地法律或监管规则的机构或人员。

本报告版权仅为本公司所有。未经本公司书面许可，任何机构或个人不得以翻版、复制、发表、引用或再次分发他人（无论整份或部分）等任何形式侵犯本公司版权。如征得本公司同意进行引用、刊发的，需在允许的范围内使用，并需在使用前获取独立的法律意见，以确定该引用、刊发符合当地适用法规的要求，同时注明出处为“华泰证券研究所”，且不得对本报告进行任何有悖原意的引用、删节和修改。本公司保留追究相关责任的权利。所有本报告中使用的商标、服务标记及标记均为本公司的商标、服务标记及标记。

### 中国香港

本报告由华泰证券股份有限公司制作，在香港由华泰金融控股（香港）有限公司向符合《证券及期货条例》及其附属法律规定的机构投资者和专业投资者的客户进行分发。华泰金融控股（香港）有限公司受香港证券及期货事务监察委员会监管，是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。在香港获得本报告的人员若有任何有关本报告的问题，请与华泰金融控股（香港）有限公司联系。



### 香港-重要监管披露

- 华泰金融控股（香港）有限公司的雇员或其关联人士没有担任本报告中提及的公司或发行人的高级人员。
- 有关重要的披露信息，请参华泰金融控股（香港）有限公司的网页 [https://www.htsc.com.hk/stock\\_disclosure](https://www.htsc.com.hk/stock_disclosure) 其他信息请参见下方 “美国-重要监管披露”。

### 美国

在美国本报告由华泰证券（美国）有限公司向符合美国监管规定的机构投资者进行发表与分发。华泰证券（美国）有限公司是美国注册经纪商和美国金融业监管局（FINRA）的注册会员。对于其在美国分发的研究报告，华泰证券（美国）有限公司根据《1934年证券交易法》（修订版）第15a-6条规定以及美国证券交易委员会人员解释，对本研究报告内容负责。华泰证券（美国）有限公司联营公司的分析师不具有美国金融监管（FINRA）分析师的注册资格，可能不属于华泰证券（美国）有限公司的关联人员，因此可能不受 FINRA 关于分析师与标的公司沟通、公开露面和所持交易证券的限制。华泰证券（美国）有限公司是华泰国际金融控股有限公司的全资子公司，后者为华泰证券股份有限公司的全资子公司。任何直接从华泰证券（美国）有限公司收到此报告并希望就本报告所述任何证券进行交易的人士，应通过华泰证券（美国）有限公司进行交易。

### 美国-重要监管披露

- 分析师林晓明、何康本人及相关人士并不担任本报告所提及的标的证券或发行人的高级人员、董事或顾问。分析师及相关人士与本报告所提及的标的证券或发行人并无任何相关财务利益。本披露中所提及的“相关人士”包括 FINRA 定义下分析师的家庭成员。分析师根据华泰证券的整体收入和盈利能力获得薪酬，包括源自公司投资银行业务的收入。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或不时会以自身或代理形式向客户出售及购买华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）华泰证券研究所覆盖公司的证券/衍生工具，包括股票及债券（包括衍生品）。
- 华泰证券股份有限公司、其子公司和/或其联营公司，及/或其高级管理层、董事和雇员可能会持有本报告中所提到的任何证券（或任何相关投资）头寸，并可能不时进行增持或减持该证券（或投资）。因此，投资者应该意识到可能存在利益冲突。

### 新加坡

华泰证券（新加坡）有限公司持有新加坡金融管理局颁发的资本市场服务许可证，可从事资本市场产品交易，包括证券、集体投资计划中的单位、交易所交易的衍生品合约和场外衍生品合约，并且是《财务顾问法》规定的豁免财务顾问，就投资产品向他人提供建议，包括发布或公布研究分析或研究报告。华泰证券（新加坡）有限公司可能会根据《财务顾问条例》第32C条的规定分发其在华泰内的外国附属公司各自制作的信息/研究。本报告仅供认可投资者、专家投资者或机构投资者使用，华泰证券（新加坡）有限公司不对本报告内容承担法律责任。如果您是非预期接收者，请您立即通知并直接将本报告返回给华泰证券（新加坡）有限公司。本报告的新加坡接收者应联系您的华泰证券（新加坡）有限公司关系经理或客户主管，了解来自或所分发的信息相关的事宜。

### 评级说明

投资评级基于分析师对报告发布日后6至12个月内行业或公司回报潜力（含此期间的股息回报）相对基准表现的预期（A股市场基准为沪深300指数，香港市场基准为恒生指数，美国市场基准为标普500指数，台湾市场基准为台湾加权指数，日本市场基准为日经225指数，新加坡市场基准为海峡时报指数，韩国市场基准为韩国有价证券指数），具体如下：

#### 行业评级

**增持：**预计行业股票指数超越基准

**中性：**预计行业股票指数基本与基准持平

**减持：**预计行业股票指数明显弱于基准

#### 公司评级

**买入：**预计股价超越基准15%以上

**增持：**预计股价超越基准5%~15%

**持有：**预计股价相对基准波动在-15%~5%之间

**卖出：**预计股价弱于基准15%以上

**暂停评级：**已暂停评级、目标价及预测，以遵守适用法规及/或公司政策

**无评级：**股票不在常规研究覆盖范围内。投资者不应期待华泰提供该等证券及/或公司相关的持续或补充信息

#### 法律实体披露

**中国：**华泰证券股份有限公司具有中国证监会核准的“证券投资咨询”业务资格，经营许可证编号为：91320000704041011J

**香港：**华泰金融控股（香港）有限公司具有香港证监会核准的“就证券提供意见”业务资格，经营许可证编号为：AOK809

**美国：**华泰证券（美国）有限公司为美国金融业监管局（FINRA）成员，具有在美国开展经纪交易商业业务的资格，经营业务许可编号为：CRD#:298809/SEC#:8-70231

**新加坡：**华泰证券（新加坡）有限公司具有新加坡金融管理局颁发的资本市场服务许可证，并且是豁免财务顾问。公司注册号：202233398E

#### 华泰证券股份有限公司

##### 南京

南京市建邺区江东中路228号华泰证券广场1号楼/邮政编码：210019

电话：86 25 83389999/传真：86 25 83387521

电子邮件：ht-rd@htsc.com

##### 深圳

深圳市福田区益田路5999号基金大厦10楼/邮政编码：518017

电话：86 755 82493932/传真：86 755 82492062

电子邮件：ht-rd@htsc.com

##### 北京

北京市西城区太平桥大街丰盛胡同28号太平洋保险大厦A座18层/

邮政编码：100032

电话：86 10 63211166/传真：86 10 63211275

电子邮件：ht-rd@htsc.com

##### 上海

上海市浦东新区东方路18号保利广场E栋23楼/邮政编码：200120

电话：86 21 28972098/传真：86 21 28972068

电子邮件：ht-rd@htsc.com

#### 华泰金融控股（香港）有限公司

香港中环皇后大道中99号中环中心53楼

电话：+852-3658-6000/传真：+852-2567-6123

电子邮件：research@htsc.com

http://www.htsc.com.hk

#### 华泰证券（美国）有限公司

美国纽约公园大道280号21楼东（纽约10017）

电话：+212-763-8160/传真：+917-725-9702

电子邮件：Huatai@htsc-us.com

http://www.htsc-us.com

#### 华泰证券（新加坡）有限公司

滨海湾金融中心1号大厦，#08-02，新加坡 018981

电话：+65 68603600

传真：+65 65091183

©版权所有2025年华泰证券股份有限公司